PRiAD 3

Podstawowe miary danych

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import cv2
# zmiana sposobu wyświetlania danych typu float
pd.options.display.float_format = "{:.2f}".format
```

1. Braki w danych

Często spotykaną sytuacją w analizie danych jest występowanie braków w macierzy (ramce) danych. Do reprezentacji brakującej danej wykorzystuje się dostępną w pakiecie `numpy` wartość "not a number" - `np.nan` .

Tworzymy ramkę danych z wartościami `nan`

In [2]:
```
df = pd.DataFrame(np.random.randn(7,5),columns=list('ABCDE'))
df.iloc[3,0] = np.nan
df.iloc[3,3] = np.nan
df.iloc[4,2] = np.nan
df.iloc[4,3] = np.nan
df.iloc[1,:] = [np.nan,np.nan,np.nan,np.nan,999]
df
```

Out[2]:

	A	B	C	D	E
0	1.09	-0.12	-0.53	-1.29	-1.79
1	nan	nan	nan	nan	999.00
2	1.75	-0.55	0.66	-0.51	1.66
3	nan	-0.40	-1.21	nan	-0.72
4	1.61	-0.41	nan	nan	2.51
5	1.38	0.32	1.16	0.93	2.19
6	0.97	-0.28	-0.07	-1.72	1.21

Miejsca w których znajdują się brakujące dane można pozyskać metodą `isnull` .

In [3]:
```
pd.isnull(df)
```

Out[3]:

	A	B	C	D	E
0	False	False	False	False	False
1	True	True	True	True	False
2	False	False	False	False	False
3	True	False	False	True	False
4	False	False	True	True	False
5	False	False	False	False	False
6	False	False	False	False	False

Zadanie Napisz funkcję zliczającą brakujące dane. Funkcja powinna zwracać dwie listy (lub wektory albo słowniki) - pierwsza zawierające liczby braków w kolejnych obiektach (wiersze), druga dla kolejnych atrybutów (kolumny).

In [4]:
```
# miejsce na rozwiązanie zadania
```

Brakujące dane mogą zostać usunięte za pomocą metody `dropna` , której argumenty decydują o szczegółowym sposobie działania.

In [5]:
```
# usuwanie wierszy (obiektów) z brakami
df.dropna()
```

Out[5]:

	A	B	C	D	E
0	1.09	-0.12	-0.53	-1.29	-1.79
2	1.75	-0.55	0.66	-0.51	1.66
5	1.38	0.32	1.16	0.93	2.19
6	0.97	-0.28	-0.07	-1.72	1.21

In [6]:
```
# usuwanie atrybutów (kolumn) z brakami
df.dropna(axis='columns')
```

Out[6]:

	E
0	-1.79
1	999.00
2	1.66
3	-0.72
4	2.51
5	2.19
6	1.21

Argument `how` określa warunek jaki musi być spełniony by obiekt mógł zostac usunięty - jeśli wszystkie jego atrybuty są nieznane (`all`) lub jeśli nieznany jest jakikolwiek jego atrybut (`any` - wartość domyślna)

In [7]:
```
print(df.iloc[:,0:4])
print(df.iloc[:,0:4].dropna(how='all'))
print(df.iloc[:,0:4].dropna(how='any'))
```

```
     A     B     C     D
0 1.09 -0.12 -0.53 -1.29
1  nan   nan   nan   nan
2 1.75 -0.55  0.66 -0.51
3  nan -0.40 -1.21   nan
4 1.61 -0.41   nan   nan
5 1.38  0.32  1.16  0.93
6 0.97 -0.28 -0.07 -1.72
     A     B     C     D
0 1.09 -0.12 -0.53 -1.29
2 1.75 -0.55  0.66 -0.51
3  nan -0.40 -1.21   nan
4 1.61 -0.41   nan   nan
5 1.38  0.32  1.16  0.93
6 0.97 -0.28 -0.07 -1.72
     A     B     C     D
0 1.09 -0.12 -0.53 -1.29
2 1.75 -0.55  0.66 -0.51
5 1.38  0.32  1.16  0.93
6 0.97 -0.28 -0.07 -1.72
```

Alternatywą do usunięcia wartości nieznanych jest wstawienie w ich miejsce pewnych ustalonych wartości. Do tego celu wykorzystuje się metodę `fillna` .

In [8]:
```
df.fillna(123)
# df.fillna(value=123) # alternatywnie
```

Out[8]:

	A	B	C	D	E
0	1.09	-0.12	-0.53	-1.29	-1.79
1	123.00	123.00	123.00	123.00	999.00
2	1.75	-0.55	0.66	-0.51	1.66
3	123.00	-0.40	-1.21	123.00	-0.72
4	1.61	-0.41	123.00	123.00	2.51
5	1.38	0.32	1.16	0.93	2.19
6	0.97	-0.28	-0.07	-1.72	1.21

Brakujące wartości mogą zostać także wypełnione wartościami z sąsiadujących obiektów znajdujących się pod (`ffill`) lub nad (`bfill`)

In [9]:
```
df.fillna(method='ffill')
```

Out[9]:

	A	B	C	D	E
0	1.09	-0.12	-0.53	-1.29	-1.79
1	1.09	-0.12	-0.53	-1.29	999.00
2	1.75	-0.55	0.66	-0.51	1.66
3	1.75	-0.40	-1.21	-0.51	-0.72
4	1.61	-0.41	-1.21	-0.51	2.51
5	1.38	0.32	1.16	0.93	2.19
6	0.97	-0.28	-0.07	-1.72	1.21

In [10]:
```
df.fillna(method='bfill')
```

Out[10]:

	A	B	C	D	E
0	1.09	-0.12	-0.53	-1.29	-1.79
1	1.75	-0.55	0.66	-0.51	999.00
2	1.75	-0.55	0.66	-0.51	1.66
3	1.61	-0.40	-1.21	0.93	-0.72
4	1.61	-0.41	1.16	0.93	2.51
5	1.38	0.32	1.16	0.93	2.19
6	0.97	-0.28	-0.07	-1.72	1.21

Zadanie W pliku `pasazerowie_lot.xls` zawarte są dane o liczbie pasażerów samolotów w latach 2005-16 w panstwach nalezacych do Unii Europejskiej oraz z nią stowarzyszonych. Dane pochodza z serwisu internetowego EUROSTAT-u (http://ec.europa.eu/eurostat/data/database). Wykonaj następujące zadania:

- wczytaj plik
- zastanów się, jaka jest najwygodniesza postać ramki danych do dalszego przetwarzania - przekształć dane do tej postaci
- usuń wszystkie obiekty, w których występuje choć jeden brak
- narysuj wykres słupkowy pokazujący łączną liczbę przewiezionych pasażerów z podziałem na lata, słupki powinny być posortowane od najkrótszego (najmniej pasażerów), do najdłuższego (najwięcej przewiezionych pasażerów)

In [11]:
```
# miejsce na rozwiązanie zadania
```

2. Miary pojedynczego atrybutu

Podstawowe miary służące do opisu pojedynczego atrybutu to miary tendencji centralnej i miary rorzutu. Miary tendencji centralnej wskazują na "środek" zbioru danych. Do podstawowych miar należą: średnia arytmetyczna, mediana i moda. Inne, przykładowe miary to średnie geometryczna, harmoniczna, ważona.

Zadanie W poniższym przykładzie wykorzystano dane o zarobkach (w tysiącach złotych) w dwóch firmach o takiej samej liczbie pracowników, umieszczone w ramce danych. Wyznaczono także przeciętne wynagrodzenie w obu firmach jako średnią arytmetyczną oraz jako medianę.

- Wyświetl wykres kolumnowy pokazujący zarobki poszczególnych pracowników w każdej z firm
- Przeanalizuj i porównaj strukturę zarobków w obu firmach
- Aplikując o pracę i mając jedynie dane o przeciętnym wynagrodzeniu, którą firmę wybrałbyś ?
- Która miara lepiej oddaje sens pojęcia "przeciętne wynagrodzenie" ?
- Z której miary i dlaczego korzysta się podając dane o przeciętnym wynagrodzeniu ?

In [12]:
```
b = pd.DataFrame(columns=['firma A', 'firma B'])
b.loc[:,'firma A']=[ 2.2, 3.4, 4.3, 4.4, 4.5, 5.5, 6.6, 5.6, 5.6, 6.0, 6.1, 6.3, 7.4, 8.5, 7.7, 7.8, 10
.2,11.3,15.1]
b.loc[:,'firma B']=[ 3.2, 3.4, 3.3, 3.4, 3.5, 4.5, 3.6, 4.4, 4.5, 5.0, 5.1, 5.3, 5.4, 5.5, 6.7, 6.8, 25
.2,30.3,35.1]
for f in [0,1]:
    print("Przeciętne wynagrodzenie - %s - jako średnia: %.2f i jako mediana %.2f"
          %(b.columns.values[f], b.iloc[:,f].mean(), b.iloc[:,f].median()))
# tu umieść kod rysujący wykres(y)
```

```
Przeciętne wynagrodzenie - firma A - jako średnia: 6.76 i jako mediana 6.10
Przeciętne wynagrodzenie - firma B - jako średnia: 8.64 i jako mediana 5.00
```

Miary tendencji centralnej są jednymi z najprostszych miar opisujących skupiska danych, klasy, grupy itp. .

In [13]:
```
# funkcja pomocnicza - statystyki klas umieszczone obok siebie
# ostatni atrybut jest decyzyjny (wskazuje na klasę)
def opisz_klasy(ramka_wej):
    df = ramka_wej.copy()
    d = df.describe()
    d.loc['klasa',:] = 'całość'
    # indeks -1 -> ostatni atrybut, zakładamy, że zawiera informację o klasie
    for k in list(df.iloc[:,-1].unique()):
        desc = df[df.iloc[:,-1] == k].describe()
        desc.loc['klasa',:] = k
        d = pd.concat([d, desc], axis=1, sort=False)
    return d
```

In [14]:
```
df = pd.read_csv('dane1.csv')
atrybuty = list(df.columns)
print(opisz_klasy(df).loc[['klasa','count','mean','50%'],:])
sns.lmplot(x=atrybuty[0], y=atrybuty[1], data=df, fit_reg=False, hue=atrybuty[-1], legend = False)
```

```
       atrybut1 atrybut2 atrybut1 atrybut2 atrybut1 atrybut2 atrybut1 atrybut2
klasa    całość   całość  klasa 3  klasa 3  klasa 1  klasa 1  klasa 2  klasa 2
count     80.00    80.00    37.00    37.00    24.00    24.00    19.00    19.00
mean      49.01    41.27    74.16    31.86    38.46    73.25    13.37    19.21
50%       47.50    34.50    74.00    31.00    39.50    72.00    14.00    20.00
```

Out[14]: <seaborn.axisgrid.FacetGrid at 0x2a6d4ca38d0>

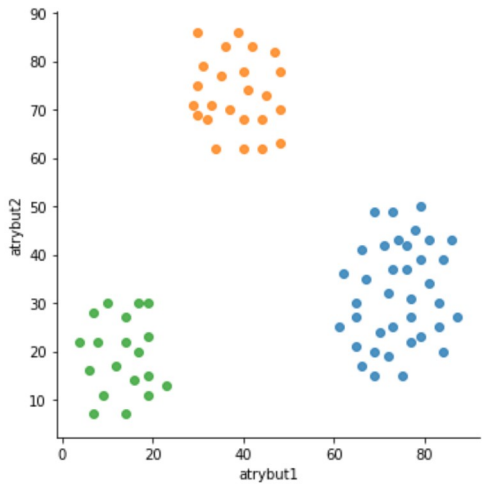

Zadanie Obserwując uzyskane w powyższym przykładzie i, ewentualnie, stosownie modyfikując kod:

- Zastanów się co mówią nam o zbiorze średnie wartości atrybutów wyznaczone dla całego zbioru i dla poszczególnych klas
- Określ położenie wartości średnich na wykresie - jakie kolory punktów na wykresie są przypisane poszczególnym klasom ?
- Wykonaj podobne eksperymenty na pozostałych zbiorach `dane2` ,..., `dane11` , wyciągnij wnioski, czy zawsze wartości średnie w klasach dobrze je opisują ?

Miary rozrzutu (rozproszenia) pozwalają na określenie stospnia skupienia danych wokół ich centrum (określonego przez miary tendencji centralnej). Podstawowymi klasycznymi miarami rozrzutu są: odchylenie standardowe, jego kwadrat czyli wariancja.

Specyficznym rodzajem miar są miary pozycyjne, które wskazują jedne z elementów w uporządkowanym (posortowanym) zbiorze danych. Do miar pozycyjnych zaliczamy: wartości skrajne (minimialną i maksymalną), oraz kwartyle. Wartości skrajne opisują zakres zmienności danego atrybutu. Kwartyle są to punkty podziału zbioru danych w proporcjach:

- pierwszy kwartyl (25%) oddziela 25% danych o najniższych wartościach od reszty
- drugi kwartyl (50%) - mediana, dzieli dane na pół
- trzeci kwartyl (75%) - rozdziela 25% danych o najwyższych wartościach od pozostałych danych o wartościach mniejszych

Różnica między trzecim i pierwszym kwartylem to rozstęp miedzykwartylowy, zaś jego połowa to odchylenie ćwiartkowe.

In [15]:
```
dane = 'dane1.csv'
df = pd.read_csv(dane)
atrybuty = list(df.columns)
print(dane)
print(opisz_klasy(df))
# wykres skrzypcowy
plt.figure(figsize=(10,5), dpi= 80)
plt.subplot(1,2,1)
sns.violinplot(x=atrybuty[-1], y=atrybuty[0], data=df)
plt.subplot(1,2,2)
sns.violinplot(x=atrybuty[-1], y=atrybuty[1], data=df)
sns.lmplot(x=atrybuty[0], y=atrybuty[1], data=df, fit_reg = False, hue=atrybuty[-1])
```

```
dane1.csv
       atrybut1 atrybut2 atrybut1 atrybut2 atrybut1 atrybut2 atrybut1 atrybut2
count     80.00    80.00    37.00    37.00    24.00    24.00    19.00    19.00
mean      49.01    41.27    74.16    31.86    38.46    73.25    13.37    19.21
std       26.01    23.38     6.96    10.20     6.42     7.53     5.47     7.66
min        4.00     7.00    61.00    15.00    29.00    62.00     4.00     7.00
25%       29.75    22.00    69.00    24.00    32.75    68.00     8.50    13.50
50%       47.50    34.50    74.00    31.00    39.50    72.00    14.00    20.00
75%       73.00    64.25    79.00    41.00    44.00    78.25    18.00    25.00
max       87.00    86.00    87.00    50.00    48.00    86.00    23.00    30.00
klasa    całość   całość  klasa 3  klasa 3  klasa 1  klasa 1  klasa 2  klasa 2
```

Out[15]:
```
<seaborn.axisgrid.FacetGrid at 0x2a6d5089a90>
```

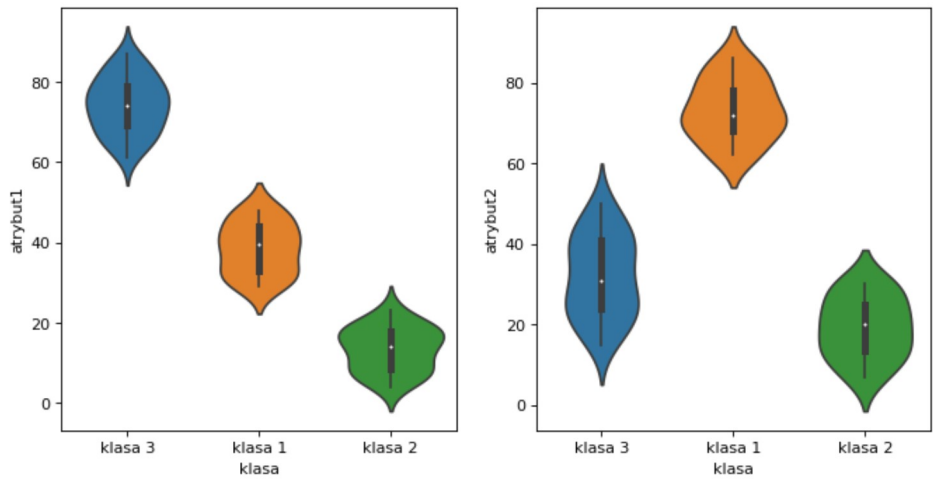

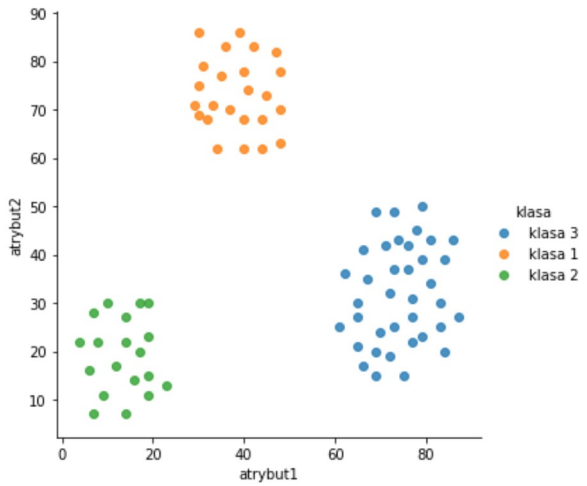

Zadanie Obejrzyj dostępne miary danych dla innych zbiorów `dane2` ,..., `dane11` . Zwróć szczególną uwagę na:

- wartość odchylenia standardowego w poszczególnych klasach - jak stopień skupienia danych wokół średniej (zaobserwuj na wykresie) przekłada się na wartość odchylenia standardowego
- położenie poszczególnych kwartyli na wykresach skrzypcowych
- jak zmiana dystrybucji punktów (wykresy) w różnych zbiorach wpływa na poszczególne miary

Zadanie Znajdź w danych z pliku `pasazerowie_lot.xls` państwa o:

- największym i najmniejszym bezwzględnym przyroście liczby pasażerów w całym obserwowanym okresie
- największym i najmniejszym względnym przyroście liczby pasażerów w całym obserwowanym okresie
- lata o największym i najmniejszym przyroście liczby pasażerów w Polsce
- lata o największym i najmniejszym przyroście liczby pasażerów we wszystkich obserwowanych państwach
- zastanów się każdorazowo nad możliwymi iterpretacjami wyników

In [16]:
```
# Miejsce na kod
```

Możliwości analizy konkretnych danych mogą istotnie wzrosnąć, jeśli dane te zostaną skojarzone z danymi pochodzącymi z innych źródeł. Poniższy przykład pokazuje, w jaki sposób można uzupełnić dane o przewozach lotniczych, ogólnodostępnymi danymi o poszczególnych państwach (wielkość populacji, powierzchnia) by obliczyć finalnie przykładowy nowy parametr - stosunek liczby przewiezionych pasażerów w 2016 roku do populacji danego państwa. Końcowy wynik jest wyświetlany dla państw liczących więcej niż 5 mln. mieszkańców.

In [17]:
```
# wczytanie danych o przewozach lotniczych
sam = pd.read_excel('pasazerowie_lot.xls', header = 2,usecols = range(0,13))
sam.index = sam['geo\\time'].rename('kraj')
sam = sam.drop(columns = ['geo\\time']).dropna() #.sort_values(by='kraj')
sam['Populacja'] = 0
sam['Powierzchnia'] = 0
# podbranie danych o krajach świata
d = pd.read_html('http://www.worldometers.info/geography/alphabetical-list-of-countries/')
kraje = d[0]
# skojarzenie danych
sam_kraje = list(sam.index);
for ind_kraju in range(0,len(sam_kraje)):
    dane_kraju = kraje[kraje.Country == sam_kraje[ind_kraju]]
    sam.iloc[ind_kraju,12] = dane_kraju.iloc[0,2] # populacja
    sam.iloc[ind_kraju,13] = dane_kraju.iloc[0,3] # powierzchnia
sam['procentowo2016']=(sam['2016']*100)/sam.Populacja
sam_duze = sam[sam.Populacja>5000000].sort_values(by = '2016')
#sam_duze = sam[sam.Populacja>5000000].sort_values(by = 'procentowo2016')
istotne_atrybuty = ['2016', 'Populacja', 'procentowo2016'];
print(sam_duze.loc[:,istotne_atrybuty ],"\n")
print(sam_duze.loc[:,istotne_atrybuty ].describe())
```

```
                       2016  Populacja  procentowo2016
kraj
Slovakia          2158261.00    5450987           39.59
Hungary          11668151.00    9655361          120.85
Czech Republic   13672362.00   10630589          128.61
Romania          15153719.00   19483360           77.78
Finland          18099954.00    5561389          325.46
Austria          27181511.00    8766201          310.07
Belgium          30115832.00   11562784          260.45
Poland           32266742.00   38028278           84.85
Denmark          32763142.00    5775224          567.31
Sweden           35952558.00   10053135          357.63
Norway           37727546.00    5400916          698.54
Portugal         40930044.00   10254666          399.14
Greece           45543371.00   11124603          409.39
Switzerland      50505492.00    8608259          586.71
Netherlands      70317995.00   17132908          410.43
Italy           134504974.00   59216525          227.14
France          145257114.00   65480710          221.83
Spain           193872037.00   46441049          417.46
Germany         200687293.00   82438639          243.44
United Kingdom  248868873.00   66959016          371.67

              2016   Populacja  procentowo2016
count        20.00       20.00           20.00
mean   69362348.55 24901229.95          312.92
std    73043668.56 25018541.22          178.78
min     2158261.00  5400916.00           39.59
25%    24911121.75  8726715.50          198.53
50%    36840052.00 10877596.00          317.76
75%    86364739.75 40131470.75          409.65
max   248868873.00 82438639.00          698.54
```

Pytanie Jak mógłbyś zinterpretować powyższe dane i ich miary wraz z wcześniejszymi obserwacjami tego samego zbioru danych ? Ja sądzisz, czy ruch lotniczy w Polsce będzie rósł w najbliższej przyszłości ?

Zadanie Wczytaj dane z pliku `waluty1.xls` . Wykorzystujac miary tendencji centralnej oraz miary rozrzutu określ dla kazdej waluty w którym półroczu którego roku (rozwaz jedynie półrocza, dla których znane sa wszystkie kursy) kurs był najwyzszy, najnizszy (biorac pod uwage jego wartosc srednia w danym okresie) oraz wykazywał najwieksza zmiennosc.

3. Miary współzależności

Miary współzależności pozwalają na określenie czy i w jakim stopniu poszczególny atrybutty sa od siebie zależne. Podstawowymi miarami zależności liniowej są korelacja i kowariancja.

In [18]:
```
# funkcja pomocnicza - macierze kowariacji i korelacji klas umieszczone obok siebie
# ostatni atrybut jest decyzyjny (wskazuje na klasę)
def opisz_klasy2(ramka_wej):
    df = ramka_wej.copy()
    d_cov = df.cov()
    d_cov.loc[:,'klasa'] = 'całość'
    d_corr = df.corr();
    d = pd.concat([d_cov, d_corr], axis=1, sort=False)
    # indeks -1 -> ostatni atrybut, zakładamy, że zawiera informację o klasie
    for k in list(df.iloc[:,-1].unique()):
        d_cov = df[df.iloc[:,-1] == k].cov()
        d_cov.loc[:,'klasa'] = k
        d_corr = df[df.iloc[:,-1] == k].corr();
        desc = pd.concat([d_cov, d_corr], axis=1, sort=False)
        d = pd.concat([d, desc], axis=0, sort=False)
    return d
```

In [19]:
```
dane = 'dane1.csv'
df = pd.read_csv(dane)
atrybuty = list(df.columns)
print(dane)
print(opisz_klasy2(df))
# wykres punktowy
plt.figure(figsize=(10,5), dpi= 80)
sns.lmplot(x=atrybuty[0], y=atrybuty[1], data=df, fit_reg = False, hue=atrybuty[-1])
```

```
dane1.csv
          atrybut1  atrybut2    klasa  atrybut1  atrybut2
atrybut1    676.52    -20.47   całość      1.00     -0.03
atrybut2    -20.47    546.51   całość     -0.03      1.00
atrybut1     48.42     11.94  klasa 3      1.00      0.17
atrybut2     11.94    104.12  klasa 3      0.17      1.00
atrybut1     41.22     -5.25  klasa 1      1.00     -0.11
atrybut2     -5.25     56.72  klasa 1     -0.11      1.00
atrybut1     29.91     -0.75  klasa 2      1.00     -0.02
atrybut2     -0.75     58.73  klasa 2     -0.02      1.00
```

Out[19]:
```
<seaborn.axisgrid.FacetGrid at 0x2a6d5146198>

<Figure size 800x400 with 0 Axes>
```

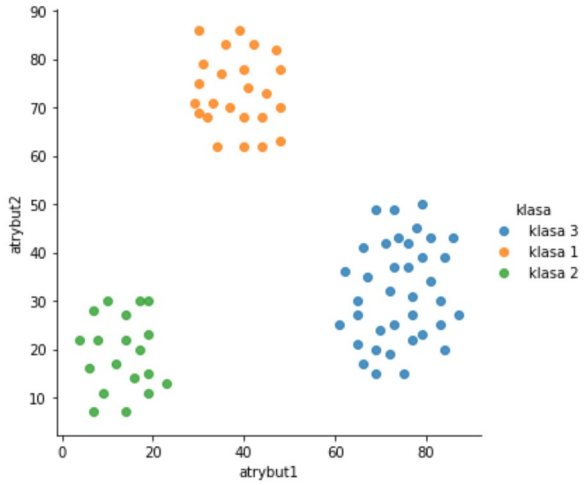

Zadanie Przeanalizuj wartości korelacji i kowariacji dla zbiory `dane1` (przykład powyżej). Jakim dystrybucjom punktów na wykresie odpowiadają różne wartości tych miar ? Wykonaj podbne eksperymenty dla pozostałych zbiorów `dane2` ,..., `dane11`

Zbiór `mtcars.csv` zawiera 12 cech kilkudziesięciu samochodów dostępnych na rynku amerykańskim w latach 70-tych. Szczegółowy opis zbioru jest dostępny w internecie (https://rpubs.com/neros/61800).

In [2]:
```
df = pd.read_csv("mtcars.csv")
df.index = df.model
df = df.drop(columns =['model'])
df.head()
```

Out[2]:

model	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.00	6	160.00	110	3.90	2.62	16.46	0	1	4	4
Mazda RX4 Wag	21.00	6	160.00	110	3.90	2.88	17.02	0	1	4	4
Datsun 710	22.80	4	108.00	93	3.85	2.32	18.61	1	1	4	1
Hornet 4 Drive	21.40	6	258.00	110	3.08	3.21	19.44	1	0	3	1
Hornet Sportabout	18.70	8	360.00	175	3.15	3.44	17.02	0	0	3	2

In [21]:
```
sns.pairplot(df, kind="scatter")
plt.show()
df.corr()
```

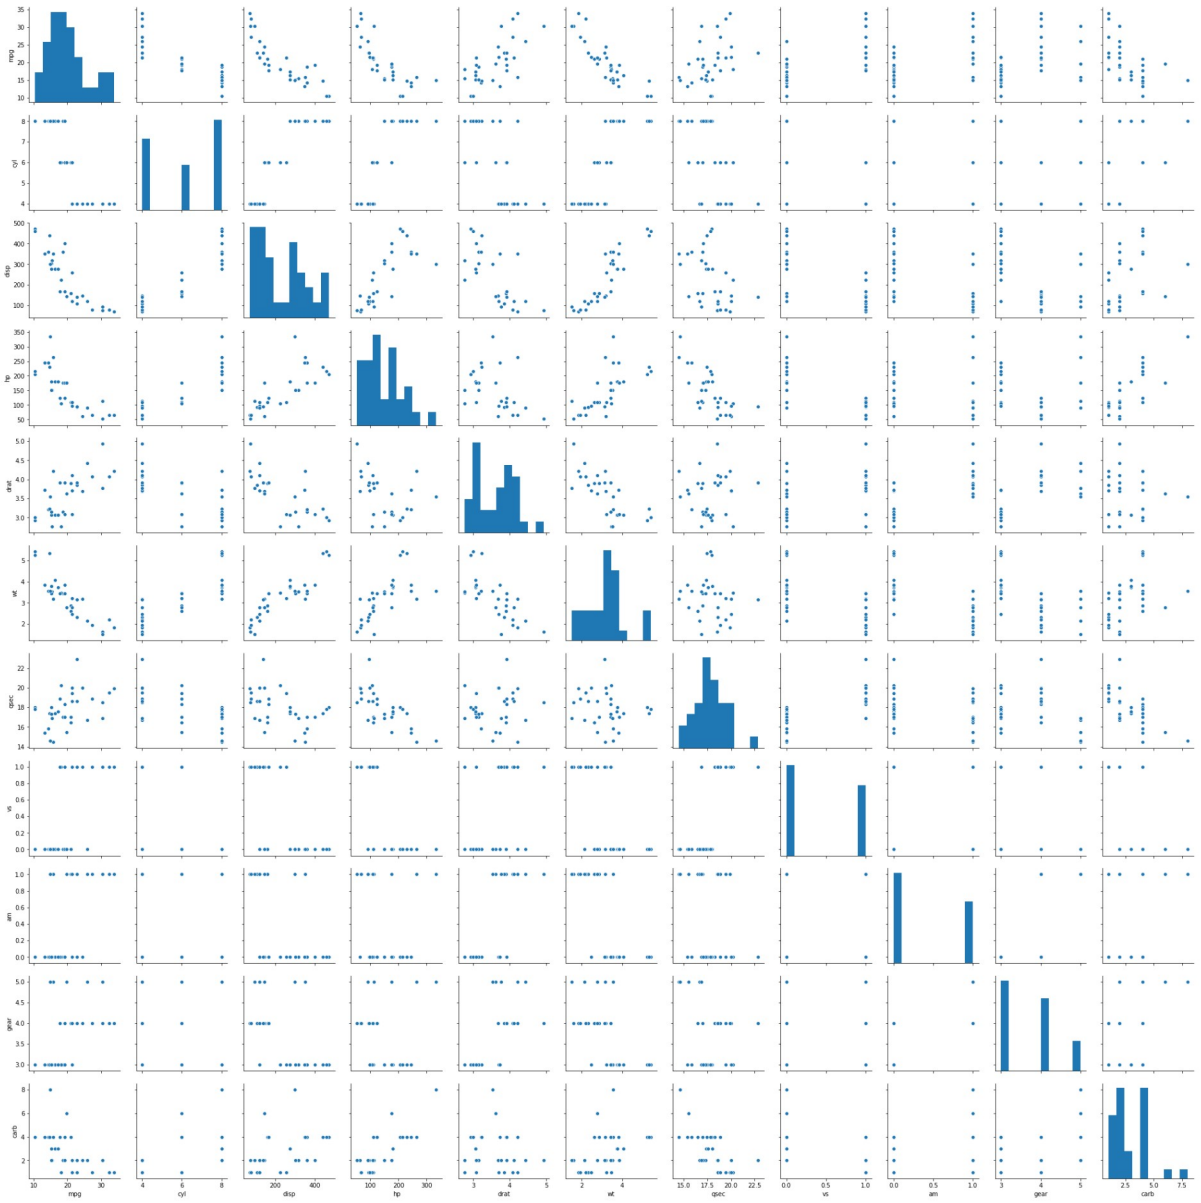

Out[21]:

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
mpg	1.00	-0.85	-0.85	-0.78	0.68	-0.87	0.42	0.66	0.60	0.48	-0.55
cyl	-0.85	1.00	0.90	0.83	-0.70	0.78	-0.59	-0.81	-0.52	-0.49	0.53
disp	-0.85	0.90	1.00	0.79	-0.71	0.89	-0.43	-0.71	-0.59	-0.56	0.39
hp	-0.78	0.83	0.79	1.00	-0.45	0.66	-0.71	-0.72	-0.24	-0.13	0.75
drat	0.68	-0.70	-0.71	-0.45	1.00	-0.71	0.09	0.44	0.71	0.70	-0.09
wt	-0.87	0.78	0.89	0.66	-0.71	1.00	-0.17	-0.55	-0.69	-0.58	0.43
qsec	0.42	-0.59	-0.43	-0.71	0.09	-0.17	1.00	0.74	-0.23	-0.21	-0.66
vs	0.66	-0.81	-0.71	-0.72	0.44	-0.55	0.74	1.00	0.17	0.21	-0.57
am	0.60	-0.52	-0.59	-0.24	0.71	-0.69	-0.23	0.17	1.00	0.79	0.06
gear	0.48	-0.49	-0.56	-0.13	0.70	-0.58	-0.21	0.21	0.79	1.00	0.27
carb	-0.55	0.53	0.39	0.75	-0.09	0.43	-0.66	-0.57	0.06	0.27	1.00

Macierz korelacji może zostać wyświetlona jako tzw."mapa ciepła", gdzie poszczególnym poziomom współczynnika odpowiadają barwy.

In [15]:
```
plt.figure(figsize=(10,10),dpi = 100)
sns.heatmap(df.corr(),annot = df.corr())
#plt.show
```

Out[15]: <matplotlib.axes._subplots.AxesSubplot at 0x1e8fa387668>

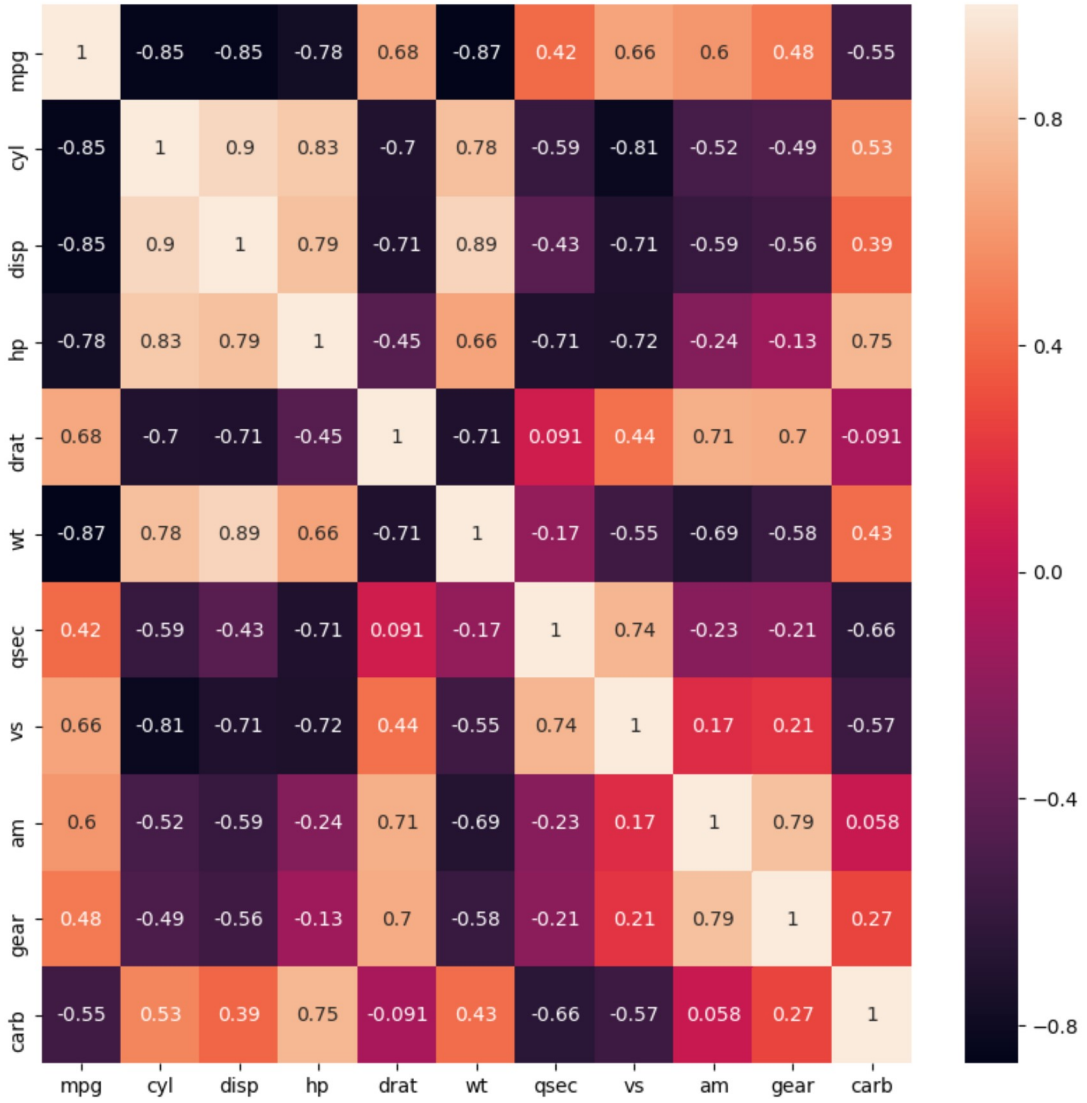

Zadanie Znajdź atrybuty najbardziej i najmniej skorelowane w macierzy `mtcars` , jak wyglądają wykresy punktowe danych skorelowanych dodatnio, ujemnie i nieskorelowanych ? W miarę możliwości spróbuj zinterpretować wyniki. Na przykład - jak skorelowane są np.:

- zużycie paliwa (mpg) z mocą silnika (hp) ?
- pojemnośc silnika (disp) i masa (wt) ?

Zadanie Napisz kod umożliwiający ocenę stopnia korelacji kursów czterech walut (`waluty1.xls`) w poszczególnych latach oraz w całym okresie dla którego dane są dostepne. Które waluty były skorelowane najmocniej, a które najsłabiej ? O czym może świadczyć korelacja kursów dwóch walut ?

4. Na zakończenie

Wykonaj komplet opisanych do tej pory analiz dla zbioru `iris.csv`

Wyznaczanie miar danych i wizualizacja danych są zadaniami uzupełniającymi się. Poznanie zbioru danych powinno polegac na wykonaniu obu tych operacji. Wykonanie tylko jednej z nich może prowadzić do nieoczekiwanych pomyłek. Przykładem na to jest tzw. kwartet Anscombe'a (https://pl.wikipedia.org/wiki/Kwartet_Anscombe%E2%80%99a).

In [22]:
```
# Wczytanie danych
d = pd.read_excel('anscombe.xlsx',header = 2,usecols = range(1,10), index_col = 0)
print(d)
```

```
      x1    y1  x2    y2  x3    y3  x4    y4
Obs.
1     10  8.04  10 9.14  10  7.46   8  6.58
2      8  6.95   8 8.14   8  6.77   8  5.76
3     13  7.58  13 8.74  13 12.74   8  7.71
4      9  8.81   9 8.77   9  7.11   8  8.84
5     11  8.33  11 9.26  11  7.81   8  8.47
6     14  9.96  14 8.10  14  8.84   8  7.04
7      6  7.24   6 6.13   6  6.08   8  5.25
8      4  4.26   4 3.10   4  5.39  19 12.50
9     12 10.84  12 9.13  12  8.15   8  5.56
10     7  4.82   7 7.26   7  6.42   8  7.91
11     5  5.68   5 4.74   5  5.73   8  6.89
```

In [23]:
```
# Zestaw 1
dd = d[['x1','y1']]
dd.columns = ['x','y']
print(dd.describe())
print(dd.corr())
plt.scatter(dd.x,dd.y)
```

```
           x      y
count 11.00 11.00
mean   9.00  7.50
std    3.32  2.03
min    4.00  4.26
25%    6.50  6.31
50%    9.00  7.58
75%   11.50  8.57
max   14.00 10.84
     x    y
x 1.00 0.82
y 0.82 1.00
```

Out[23]: <matplotlib.collections.PathCollection at 0x2a6d9d2b320>

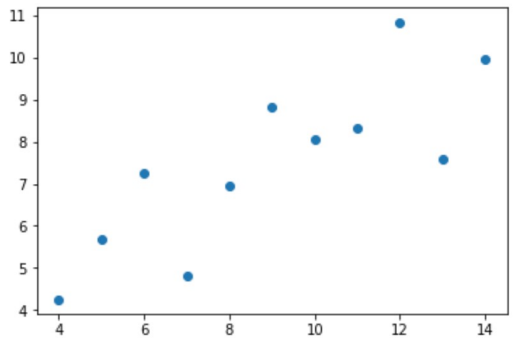

In [24]:
```
# Zestaw 2
dd = d[['x2','y2']]
dd.columns = ['x','y']
print(dd.describe())
print(dd.corr())
plt.scatter(dd.x,dd.y)
```

```
              x      y
count  11.00 11.00
mean    9.00  7.50
std     3.32  2.03
min     4.00  3.10
25%     6.50  6.70
50%     9.00  8.14
75%    11.50  8.95
max    14.00  9.26
      x    y
x  1.00 0.82
y  0.82 1.00
```

Out[24]: <matplotlib.collections.PathCollection at 0x2a6dbe9cf60>

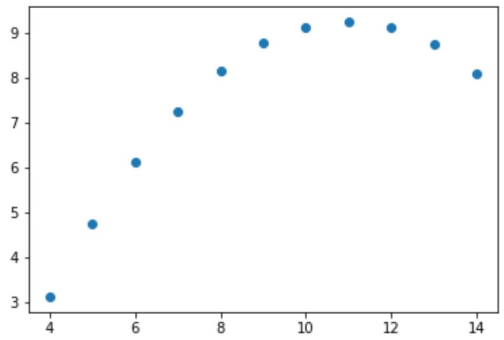

In [25]:
```
# Zestaw 3
dd = d[['x3','y3']]
dd.columns = ['x','y']
print(dd.describe())
print(dd.corr())
plt.scatter(dd.x,dd.y)
```

```
              x      y
count  11.00 11.00
mean    9.00  7.50
std     3.32  2.03
min     4.00  5.39
25%     6.50  6.25
50%     9.00  7.11
75%    11.50  7.98
max    14.00 12.74
      x    y
x  1.00 0.82
y  0.82 1.00
```

Out[25]: <matplotlib.collections.PathCollection at 0x2a6dbef3128>

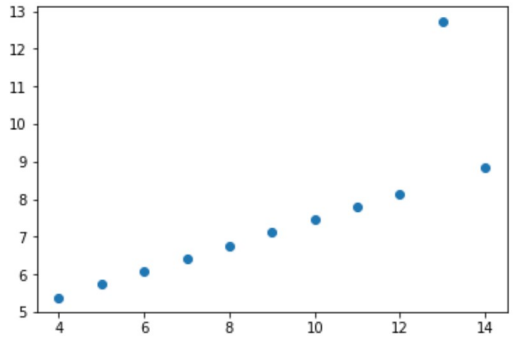

In [26]:
```
# Zestaw 4
dd = d[['x4','y4']]
dd.columns = ['x','y']
print(dd.describe())
print(dd.corr())
plt.scatter(dd.x,dd.y)
```

```
              x      y
count  11.00 11.00
mean    9.00  7.50
std     3.32  2.03
min     8.00  5.25
25%     8.00  6.17
50%     8.00  7.04
75%     8.00  8.19
max    19.00 12.50
      x    y
x  1.00 0.82
y  0.82 1.00
```

Out[26]: <matplotlib.collections.PathCollection at 0x2a6dbf4ca20>

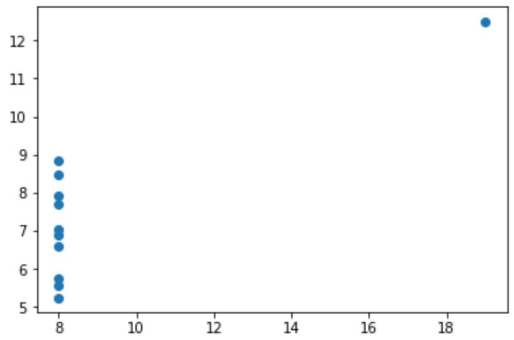

Pytanie Co pokazuje kwartet Anscombe'a i jakie wnioski można z niego wyciągnąć ?

Dla dociekliwych

- How to investigate a dataset with python? (https://towardsdatascience.com/hitchhikers-guide-to-exploratory-data-analysis-6e8d896d3f7e)
- Wariancja, kowariancja i korelacja (https://pythonfordatascience.org/variance-covariance-correlation/)
- Kowariancja i korelacja (https://towardsdatascience.com/let-us-understand-the-correlation-matrix-and-covariance-matrix-d42e6b643c22)
- Kwartet Anscombe'a (https://vknight.org/unpeudemath/mathematics/2016/10/29/anscombes-quartet-variability-and-ciw.html)